

实验 2：个人软件选题与需求分析

个人项目：面向数模的特征衍生系统（FeaturePilot）

班级：_____ 学号：_____ 姓名：_____

2026 年 9 月 15 日

目录

学习通提交说明	2
1 实验目的	2
2 实验内容	2
2.1 选题来源与问题陈述	2
2.2 用户画像与典型场景	3
2.3 现有方案与差异化	3
2.4 用户故事、需求与验收条件	3
2.5 AI 能力必要性与可行性	3
2.6 MVP(Minimum Viable Product) 范围与第 2—17 周计划	4
3 操作记录	4
3.1 选题来源与问题陈述	4
3.2 用户画像与典型场景	4
3.3 现有方案与差异化	5
3.4 用户故事、需求与验收条件	6
3.5 AI 能力必要性与可行性	7
3.6 MVP 范围与第 2—17 周计划	8
4 实验小结	10

学习通提交说明

- **提交平台：**只向学习通对应的“实验报告”作业上传一份 PDF 文件。
- **文件命名：**班级-学号-姓名-实验 2-个人软件选题与需求分析.pdf。
- **PDF 内容：**个人项目方案、需求说明 V1、用户与场景证据、现有方案比较、用户故事与验收条件、AI 能力分析及第 2—17 周个人计划。
- **截止时间：**以学习通作业设置为准；报告中的仓库链接与 Commit 用于过程核验。

1 实验目的

- 围绕真实或明确的用户问题完成个人软件选题，形成可在课程周期内独立完成的项目范围。
- 掌握用户、场景、功能需求、非功能需求、用户故事和验收条件的表达方法。
- 判断 AI 能力是否真正必要，并明确其输入、输出、价值、风险和非 AI 降级方案。

相关课程参考

- [Harvard CS85: Introduction to Generative AI via Building Software for the Study of Arts & Sciences \(2026 课程目录\)](#)：参考其从真实领域问题出发、再把问题转换为软件需求的组织方式。本实验要求先说明用户和实际困难，再决定使用什么 AI 技术。
- [Harvard CS50: Final Project \(2026\)](#)：参考其自主选题、解决真实问题和确定项目里程碑的做法。本课程将其调整为一人一款软件，并在需求阶段明确核心价值、范围和验收条件。

2 实验内容

2.1 选题来源与问题陈述

- 用“目标用户—当前情境—主要困难—造成影响—拟解决方式”描述问题，避免使用空泛技术口号。
- 通过一次简短访谈、现场观察、个人真实经历或公开需求材料说明选题来源，并保留问题记录、观察摘要或资料链接等证据。
- 用一句话概括软件的核心价值，并说明用户在使用前后会发生什么可以观察到的变化。

2.2 用户画像与典型场景

- 至少定义 1 类主要用户，说明其目标、能力、使用环境、约束与痛点；项目存在管理者、内容提供者或其他使用者时，再补充相应的次要用户。
- 用具体场景描述用户如何进入软件、完成任务、获得结果，以及失败时如何处理。
- 为主要用户补充至少 4 个正常场景和 2 个异常场景，说明两种情况下软件分别应该如何响应。

2.3 现有方案与差异化

- 调研至少 2 个现有相似的产品、人工流程或开源方案，从功能、成本、隐私、易用性和 AI 能力等方面比较。
- 指出本项目不准备解决的问题，防止需求边界不断扩大。
- 总结现有方案中可以借鉴的设计和仍未解决的问题，明确本项目准备形成的差异。

2.4 用户故事、需求与验收条件

- 采用“作为……我希望……以便……”编写用户故事，并用“给定—当—那么”(Given/When/Then) 写验收条件。
- 建立用例图、用例描述：编号、描述、优先级、来源、依赖、验收方法等；非功能需求至少覆盖性能、可靠性、安全或可用性中的两类。
- 围绕最核心的用户流程编写 3—5 个可直接用于后续实验的验收示例，至少包含正常情况、信息不足或失败情况以及需要人工确认的情况。

2.5 AI 能力必要性与可行性

- 说明 AI 处理的任务为何难以完全用固定规则解决，明确模型输入、期望输出、允许错误和人工确认点。
- 分析数据来源、模型服务、费用、时延、隐私、幻觉和评测难点，给出非 AI 降级方案。
- 从 2.4 的验收示例中选择至少 3 组，补充输入、期望输出和判定方法，其中包含 1 组无法处理或需要人工确认的情况。

2.6 MVP(Minimum Viable Product) 范围与第 2—17 周计划

- 形成一页个人项目方案，确定本学期只重点完成的一条核心用户流程，列出纳入 MVP 的功能和明确不在本学期实现的功能。
- 列出每一阶段的可运行成果、验收条件和风险，确保一人能够在课程周期内完成。
- 把计划落实到每周可检查的任务和阶段演示节点，并为可能延期的功能预留删减或替代方案。

3 操作记录

3.1 选题来源与问题陈述

本选题来源于本人参加数学建模与数据分析时的真实经历。比赛前期需要反复查看列含义、统计分布并手写交叉特征，容易出现除零、负数取对数、时间编码错误和数据泄露等问题。目标用户是具备 Python/Pandas 基础、但时间紧且特征工程经验有限的数学建模参赛者。主要困难是传统工具只给统计图，或一次生成大量难以解释的特征，影响建模速度和论文表达。

拟开发的 FeaturePilot 是轻量级“特征副驾驶”：用户上传 CSV、选择目标列并填写一句赛题背景后，系统在本地完成统计与风险扫描，由 AI 推荐少量有机理解释的候选特征，再经白名单算子校验后生成安全的 Pandas 代码。其核心价值是：**在不上传全量原始数据的前提下，把人工筛选和编写特征代码的过程缩短为一次可解释、可确认的交互流程。**

3.2 用户画像与典型场景

主要用户为本科数学建模参赛者。其目标是在有限时间内获得可解释、可运行的衍生特征；具备基础 Python 能力，主要在个人电脑上使用；约束包括比赛时间短、数据质量不稳定、网络或模型服务可能不可用。其痛点是特征构造依赖经验、重复编码多且容易引入错误。

表 1: 典型使用场景及系统响应

类型	场景	用户操作与目标	系统响应
正常	有 监 督 回 归	上传能耗数据，选择能耗列并填写“预测锅炉能耗”	计算相关性和互信息，推荐少量可解释特征并提供预览

类型	场景	用户操作与目标	系统响应
正常	有 监 督 分 类	选择类别标签与分类任务	按分类目标打分，输出结构化推荐
正常	无 监 督 分 析	不选择目标列，希望压缩冗余并发现结构	使用方差、偏度和 PCA 载荷生成低冗余候选
正常	导出代码	勾选已通过校验的候选特征	生成带除零、负数保护注释的 Pandas 脚本
异常	输 入 不 合 法	上传缺列、空表或无法解析的 CSV	停止分析，指出具体问题，不生成误导性结果
异常	高 风 险 特 征	检测到镜像列或 40%–70% 缺失列	以红/黄卡片警示并默认锁定，等待用户逐项确认

3.3 现有方案与差异化

表 2: 现有方案比较

方案	功能	成本	隐私	易用性	AI 能力
Featuretools	自动组合、聚合特征，覆盖面广	开源，但大量特征增加计算成本	可本地运行	需要理解实体与原语配置	不理解赛题语义
ydata-profiling	自动生成分布、缺失率和相关性报告	开源，本地资源消耗可控	可本地运行	报告直观	主要描述数据，不主动给出机理特征
人工 流程	Pandas 灵活、完全可控	时间与经验成本高	数据留在本地	重复编码多、易出错	依赖个人经验
FeaturePilot	统计筛选、语义推荐、风险确认与安全代码导出	MVP 采用轻量本地模块，模型调用按次产生少量费用	原始数据不上传，只发送元数据画像	单页流程，候选少且可解释	用于机理解释，失败时可降级为规则引擎

可借鉴之处是 Featuretools 的算子思想和 ydata-profiling 的统计概览；仍未解决的问题是“统计异常如何结合赛题背景转化为少量可解释特征”。本项目的差异是“本地统计事实 + AI 语义推理 + 人工确认 + 白名单代码生成”。本学期不实现模型自动调参、自

动训练与部署、多人协作、数据库和大规模分布式计算，避免演变为完整 AutoML 平台。

3.4 用户故事、需求与验收条件

核心用户故事如下：

- 作为数学建模参赛者，我希望上传 CSV 并选择目标列，以便系统按有监督或无监督模式分析数据。
- 作为数学建模参赛者，我希望看到少量带理由和风险等级的候选特征，以便快速判断其是否有现实意义。
- 作为数学建模参赛者，我希望一键导出安全的 Pandas 代码，以便直接加入比赛脚本。
- 作为谨慎的使用者，我希望高风险特征默认不可选，以便避免误用泄露列或高缺失列。




图 1: FeaturePilot 核心用例图

表 3: 核心用例描述

编号	描述	优先级	来源	依赖	验收方法
UC01	上传 CSV 并生成本地数据画像	P0	个人经历	Pandas/NumPy	合法文件可得到列统计;非法文件有明确提示
UC02	按目标与背景推荐候选特征	P0	核心价值	UC01、模型服务	返回规定 JSON 字段,列名和算子均可校验

编号	描述	优先级	来源	依赖	验收方法
UC03	展示风险并要求人工确认	P0	泄露风险	UC01、风险规则	红/黄项默认锁定，确认后才可选择
UC04	导出安全 Pandas 代码	P0	编码痛点	UC02、UC03、算子注册表	导出脚本可运行且无 <code>exec/eval</code>
UC05	离线规则推荐	P1	弱网约束	UC01	模型不可用时仍能产生规则候选

核心验收示例：

1. **正常情况**：给定包含数值列、有效目标列的 CSV，当用户提交分析时，那么系统应显示数据画像和不超过 $\text{Top-}k$ 的结构化候选特征。
2. **无监督情况**：给定用户选择“无特定目标”，当系统分析时，那么推荐不得依赖标签，并应依据方差、偏度或 PCA 载荷说明理由。
3. **信息不足/失败**：给定空表、目标列不存在或模型服务超时，当用户提交时，那么系统应给出明确提示；服务超时则启用本地规则引擎，不得崩溃。
4. **人工确认**：给定候选特征引用相关系数 $r \geq 0.999$ 的镜像列或临界缺失列，当结果展示时，那么该项必须默认锁定；只有用户逐项确认后才能导出。
5. **代码安全**：给定包含零分母和负数的输入，当用户导出并运行代码时，那么安全除法不得抛出除零异常，对数变换应先平移到非负区间，且代码中不得出现 `exec()` 或 `eval()`。

非功能需求：常规赛题数据画像采用最多 20,000 行下采样，目标为个人电脑上秒级返回；模型服务失败时自动降级，保证基本功能可用；原始数据仅在本地处理，发送给模型的内容限于 Schema、统计指标和赛题背景；页面必须明确区分绿、黄、红风险，并给出可理解的错误信息。

3.5 AI 能力必要性与可行性

固定规则能够发现偏度、缺失率和相关性，却难以理解“压力、容积与做功”这类依赖赛题背景的机理关系，因此 AI 只负责语义推理，不直接执行代码。模型输入为列名、类型、统计摘要、风险名单、目标任务和一句话背景；输出固定为 `feature_name`、`op`、`params`、`reason`。允许模型漏掉有用候选或给出被过滤的建议，但不允许未知列名、未注册算子和高风险项绕过人工确认。

表 4: AI 验收输入、期望输出与判定方法

组别	输入	期望输出	判定方法
A	合法 Schema、回归目标、锅炉能耗背景	基于真实列名给出受控算子及机理理由	JSON 可解析；算子命中注册表；参数均存在于列集合
B	无目标列、含高偏态数值列	明确标识无监督模式，可推荐 log1p 等低冗余变换	输出不引用标签；理由对应方差、偏度或 PCA 指标
C	含镜像列或 55% 缺失列	拒绝自动放行，提示需要人工确认或跳过	界面默认锁定；未经确认无法进入导出脚本

可行性方面，Pandas/NumPy 可完成本地统计和安全执行，模型仅接收精简元数据，费用与时延可控。主要风险为模型幻觉、网络失败和统计指标误导；对应措施分别是 JSON Schema 与白名单校验、本地规则降级和人工确认。评测以“结构化输出合法率、代码运行成功率、风险拦截率、推荐理由可理解性”为主，不单独以模型准确率作为结论。

3.6 MVP 范围与第 2—17 周计划

本学期只重点完成一条核心流程：上传 CSV 与填写背景 → 本地画像与风险扫描 → 生成并筛选可解释特征 → 预览并导出安全 Pandas 代码。MVP 包含有/无监督切换、五类安全算子、模型推荐、离线降级、红黄绿风险提示和代码下载；明确不包含自动训练调参、云端数据存储、多人协作和分布式计算。

表 5: 第 2—17 周个人计划

周次	可检查任务/成果	验收条件	风险与替代
第 2 周	明确用户、问题、核心流程与边界	完成需求说明 V1	范围过大则删除 AutoML 功能
第 3 周	整理场景、用户故事和验收条件	4 正常、2 异常场景可复核	证据不足则补个人观察记录
第 4 周	搭建 Streamlit 页面与 CSV 上传	合法文件可读取，异常有提示	先支持 UTF-8 CSV
第 5 周	实现描述统计和特殊列识别	输出缺失率、偏度、唯一率等	大数据先采样

周次	可检查任务/成果	验收条件	风险与替代
第 6 周	实现有监督相关性与互信息	可选择回归/分类目标	先完成回归路径
第 7 周	实现无监督方差、偏度与 PCA 指标	无目标时不引用标签	PCA 延期则先保留方差/偏度
第 8 周	实现镜像列和缺失率风险扫描	阈值样例全部正确标记	阈值改为可配置常量
第 9 周	建立五类 SafeOperatorRegistry 算子	单元测试覆盖异常输入	先保留除法、对数、交叉
第 10 周	完成结构化 Prompt 与 JSON 校验	未知列、未知算子均被拦截	模型不稳定则加强 Schema
第 11 周	实现本地规则降级	断网时可返回候选	减少规则数量保证稳定
第 12 周	完成候选卡片和可视化预览	变换前后结果可对比	KDE 延期则保留直方图
第 13 周	完成红黄卡锁定与逐项确认	未确认项无法勾选	状态只保留当前会话
第 14 周	完成代码拼装、复制与下载	导出脚本可独立运行	先保证下载功能
第 15 周	集成测试与典型数据集演示	核心流程连续运行成功	固化一份演示数据
第 16 周	性能、可靠性和可用性修正	常规数据秒级画像，错误可理解	减少采样量与图表数量
第 17 周	整理文档、演示视频和最终提交	报告、仓库、Commit 可核验	非核心功能停止追加

过程材料保存位置为面向数模的特征衍生系统（FeaturePilot）系统设计与需求说明书.md；实验要求文件为实验 2-个人软件选题与需求分析.md。当前本地目录尚未初始化为 Git 仓库，提交前应补充：仓库链接_____，对应 Commit _____。

4 实验小结

本实验最终确定的选题为 FeaturePilot，其核心用户流程是上传 CSV 和赛题背景，经本地画像与风险扫描后获得少量可解释的衍生特征，并导出经过白名单校验的 Pandas 代码。MVP 边界聚焦于特征推荐、风险确认和安全代码生成，不扩展为自动训练、调参和部署平台。AI 的必要性在于结合列语义与赛题背景提出机理候选；统计计算、代码执行和风险放行仍由本地程序与用户控制。

分析过程中发生的主要取舍是：最初可能采用大模型直接生成自由 Python 公式，随后改为“大模型只输出受控算子 JSON，本地注册表执行并拼装代码”。该变化减少了灵活性，但能够拦截幻觉列名、语法错误和任意代码执行风险，更符合个人项目在课程周期内可实现、可测试和可解释的要求。同时删去完整 AutoML、多用户协作和分布式计算，把时间集中在一条可运行的核心流程上。